



Universidade Lusófona do Porto
Engenharia Eletrotécnica de sistemas de energia
Estado de arte

Previsão de séries temporais de energia com IA Generativa

Trabalho realizado por:
Caetano G. Policarpo Luís

1. Introdução e Contextualização

A previsão de séries temporais no setor energético é um domínio de importância estratégica crescente. A exatidão na antecipação de padrões de consumo e produção de energia reveste-se de um papel crucial na gestão eficiente da rede elétrica, no planejamento operacional, na integração de fontes renováveis e na atuação em mercados liberalizados.

Com a transição energética em curso — marcada pela eletrificação do consumo, descentralização da produção e variabilidade das fontes renováveis — emergem novos desafios que exigem soluções tecnológicas avançadas. Neste contexto, a *Inteligência Artificial Generativa* (*Generative Artificial Intelligence, GenAI*) destaca-se como uma abordagem promissora para superar as limitações dos métodos convencionais de previsão.

Ao contrário dos modelos discriminativos, que aprendem uma correspondência direta entre entrada e saída, os modelos generativos procuram capturar a distribuição subjacente dos dados. Essa capacidade de modelar incertezas, gerar amostras sintéticas realistas e representar padrões complexos torna-os particularmente adequados para séries temporais de energia, caracterizadas por sazonalidade múltipla, ruído e eventos raros.

Este capítulo revê os desenvolvimentos mais recentes (2023–2025) na aplicação de modelos *GenAI* à previsão de séries temporais energéticas, com ênfase nos modelos mais promissores, seus desafios técnicos e o seu potencial no contexto do projeto de estágio.

2. Modelos Generativos Relevantes para Séries Temporais de Energia

2.1 Modelos Baseados em *Transformers*

Os modelos *Transformer*, originalmente propostos para tarefas de processamento de linguagem natural, têm vindo a ser adaptados com sucesso para o domínio das séries temporais.

- Time Series Transformer (*TST*): Adaptado a partir da arquitetura original, permite gerar sequências futuras com base em entradas anteriores, explorando mecanismos de atenção para captar dependências de longo alcance.
 - *Vantagens*: Escalabilidade, paralelização e robustez à variabilidade dos dados.
 - *Relevância para o estágio*: Investigação de *Transformers* generativos para previsão de padrões complexos de consumo energético, utilizando atenção contextual para isolar variáveis-chave como temperatura, horários ou padrões de comportamento.
- Variational Transformer Networks (*VTN*): Integram inferência variacional à arquitetura *Transformer*, permitindo a modelação explícita da incerteza nas previsões.

- *Vantagens*: Previsões probabilísticas com intervalos de confiança.
- *Relevância para o estágio*: Implementação de *VTN* para previsão energética em cenários com elevado ruído ou escassez de dados históricos.

2.2 Redes Adversariais Generativas (GANs)

As *Generative Adversarial Networks (GANs)* têm demonstrado notável capacidade na geração de dados temporais sintéticos.

- TimeGAN: Modelo híbrido que combina uma rede recorrente com um gerador e um discriminador, promovendo a aprendizagem de dinâmicas temporais realistas.
 - *Avanços*: Introdução de variantes condicionais (*Conditional GANs*, *CGANs*) para incorporação de variáveis exógenas como meteorologia, calendários ou padrões económicos.
 - *Relevância para o estágio*: Exploração de *TimeGAN* condicional alimentado com dados exógenos de Portugal (temperatura, radiação UV, eventos culturais, entre outros).
- Diffusion Models: Inicialmente aplicados à geração de imagens, os modelos de difusão começam a ser explorados para séries temporais, baseando-se num processo reversível de adição e remoção de ruído.
 - *Vantagens*: Qualidade das amostras, estabilidade de treino.
 - *Relevância para o estágio*: Aplicação experimental de *Diffusion Models* à previsão de consumo energético e comparação com outras abordagens generativas.

2.3 Outras Abordagens

- Modelos Auto-Regressivos Generativos: Capturam a probabilidade condicional de cada ponto temporal com base no histórico observado.
- Modelos *Flow-Based*: Utilizam transformações invertíveis para mapear dados reais em distribuições latentes simples, facilitando a geração inversa de novas amostras.

3. Desafios Específicos na Modelação de Séries Temporais de Energia

A aplicação de modelos *GenAI* ao setor energético acarreta desafios particulares, tais como:

- **Estacionaridade não trivial:** Padrões sazonais sobrepostos (diários, semanais, anuais) exigem modelos capazes de representar múltiplas escalas temporais simultaneamente.
- **Eventos raros e anómalos:** Situações como picos de consumo anómalos devem ser corretamente representadas ou antecipadas pelas distribuições geradas.
- **Dependências de longo alcance:** Algumas dinâmicas de consumo manifestam efeitos retardados, exigindo memória contextual extensa.
- **Variáveis exógenas:** Fatores como feriados, condições climáticas ou flutuações económicas devem ser incorporados para melhorar a precisão.
- **Avaliação robusta:** Métricas tradicionais como *MAE* ou *RMSE* podem ser insuficientes; é essencial considerar métricas de incerteza (e.g., cobertura de intervalos preditivos) e fidelidade estatística.

4. Aplicações e Casos de Uso Emergentes

Modelos *GenAI* já demonstram impacto relevante em diversas aplicações do setor energético:

- Geração de múltiplos cenários: Criação de conjuntos de previsões plausíveis para análise de risco e planeamento estocástico.
- Imputação e aumento de dados: Geração de dados sintéticos para colmatar lacunas em séries incompletas.
- Detecção de anomalias: Identificação de padrões atípicos por contraste com distribuições modeladas.
- Otimização de estratégias de *trading*: Utilização de previsões probabilísticas para suportar decisões em mercados de energia.

5. Direções Futuras e Integração com o Projeto de Estágio

Tendo em conta o estado da arte, as seguintes linhas de investigação revelam-se promissoras para aprofundamento no âmbito do projeto:

- Avaliação comparativa entre *Transformer*, *TimeGAN* e *Diffusion Models* com dados reais de Portugal.
- Incorporação sistemática de variáveis contextuais externas nos modelos generativos.
- Exploração da capacidade dos modelos para previsão probabilística e quantificação de incerteza.
- Aplicação de *GenAI* para imputação de dados em falta ou simulação de cenários extremos.
- Análise do desempenho com métricas específicas para séries temporais probabilísticas.

Referências

- Giacomazzi, M., Lemaire, C., Codato, G., Debusschere, V., & Noury, M. (2023). *Short-Term Load Forecasting Using Temporal Fusion Transformers: A Substation-Level Study*. arXiv. <https://arxiv.org/abs/2305.10559>
- Lin, W., Li, Y., Cao, Y., & Wang, J. (2024). *EnergyDiff: Diffusion Models for Realistic Energy Time-Series Generation*. arXiv. <https://arxiv.org/abs/2407.13538>
- López Santos, F., Fernández-Rodríguez, A., & García-González, J. (2022). *Day-Ahead Photovoltaic Power Forecasting Using Temporal Fusion Transformer*. *Energies*, 15(14), 5232. <https://doi.org/10.3390/en15145232>
- Yoon, J., Jarrett, D., & van der Schaar, M. (2019). *Time-series Generative Adversarial Networks*. arXiv. <https://arxiv.org/abs/1907.05321>

Lista de Acrónimos Lista de Acrónimos

GenAI - Generative Artificial Intelligence (Inteligência Artificial Generativa)

TST - Time Series Transformer

VTN - Variational Transformer Networks

GAN - Generative Adversarial Network (Rede Generativa Adversarial)

CGAN - Conditional GAN (GAN Condicional)